



UNIVERSIDADE FEDERAL DO CEARÁ

CENTRO DE CIÊNCIAS

DEPARTAMENTO DE ESTATÍSTICA E MATEMÁTICA APLICADA

CURSO DE GRADUAÇÃO EM ESTATÍSTICA

DOUGLAS CHAVES MOURA

Lista de Exercícios Prática II - Séries Temporais

FORTALEZA

2025

DOUGLAS CHAVES MOURA

Lista de Exercícios Prática II - Séries Temporais

Trabalho apresentado à disciplina Análise de Séries Temporais, do curso de Graduação em Estatística do Centro de Ciências da Universidade Federal do Ceará, como parte dos requisitos para a avaliação da referida disciplina, no semestre 2025.1.

Professora: Dr^a Jeniffer Johana Duarte Sanchez

FORTALEZA

2025

Lista de Figuras

2.1	Gráfico da Série Temporal de Níveis de Ozônio (1956-1970).	3
2.2	Boxplot dos níveis de ozônio por mês.	4
2.3	Decomposição Multiplicativa da Série Temporal.	4
3.1	ACF e PACF da série original de ozônio.	6
3.2	Diagnóstico dos resíduos (ACF e PACF) para o Modelo 1.	7
3.3	Diagnóstico dos resíduos (ACF e PACF) para o Modelo 2.	8
3.4	Valores-p para o Teste de Ljung-Box - Modelo 2.	9
3.5	Q-Q Plot dos resíduos – Modelo 2.	9
4.1	Previsões para os próximos 12 meses com o Modelo 2.	11

Lista de Tabelas

2.1	Estatísticas descritivas dos níveis de ozônio (1956–1970).	2
2.2	Estatísticas descritivas dos níveis de ozônio por mês (1956–1970).	2
4.1	Resumo comparativo dos indicadores para os modelos candidatos.	10

Sumário

Lista de Figuras

Lista de Tabelas

1	Introdução	1
2	Análise Exploratória e Descritiva	2
2.1	Descrição e Visualização dos Dados	2
2.2	Decomposição da Série	4
2.3	Testes Formais na Série Original	5
2.3.1	Teste para Estacionariedade	5
2.3.2	Teste para Tendência	5
2.3.3	Teste para Sazonalidade	5
3	Metodologia Box-Jenkins: Identificação, Estimação e Diagnóstico	6
3.1	Identificação dos Parâmetros	6
3.2	Diagnóstico dos Modelos	7
3.2.1	Modelo 1: SARIMA(1,0,0)(0,1,1) ₁₂	7
3.2.2	Modelo 2: SARIMA(1,0,9)(0,1,1) ₁₂ com Parâmetros Fixos	8
4	Escolha do Modelo Ideal e Previsão	10
4.1	Análise Comparativa dos Resultados	10
4.2	Previsão	10
5	Apêndice A	12
5.1	Lista de Códigos	12
	Referências Bibliográficas	18

1 Introdução

Este relatório detalha a construção de um modelo SARIMA (Seasonal Autoregressive Integrated Moving Average) para a série temporal de níveis mensais de ozônio, abrangendo o período de 1956 a 1970.

A base de todo o desenvolvimento metodológico foi coletada do livro "Análise de Séries Temporais" de [Morettin e Tolo \(2006\)](#), além dos conceitos vistos em sala de aula. A metodologia principal a ser seguida é a de Box-Jenkins para modelos ARIMA.

Toda a aplicação será desenvolvida no software R (Versão 4.4.2) ([R Core Team, 2024](#)), através da IDE (Integrated Development Environment) RStudio (Versão 2024.12.0.467) ([Posit team, 2024](#)).

2 Análise Exploratória e Descritiva

2.1 Descrição e Visualização dos Dados

A série temporal em estudo refere-se aos níveis mensais de ozônio, coletados entre janeiro de 1956 e dezembro de 1970, totalizando 180 observações. Trata-se de uma série univariada e discreta, com frequência mensal. As principais estatísticas descritivas da variável estão apresentadas na Tabela 2.1.

Tabela 2.1: Estatísticas descritivas dos níveis de ozônio (1956–1970).

Variável	Média	DP	Mediana	Min	Max	<i>n</i>
Nível de Ozônio	5,8	2,01	4,8	1,6	9,5	180


Considerando a natureza mensal da série, as estatísticas descritivas também foram analisadas para cada mês, conforme apresentado na Tabela 2.2. Observa-se uma clara variação sazonal nos níveis de ozônio, com médias mais elevadas durante os meses de verão (junho a agosto), atingindo o pico em julho (8,21), e valores mais baixos nos meses de inverno (novembro a janeiro), com o menor valor observado em dezembro (2,63).

Tabela 2.2: Estatísticas descritivas dos níveis de ozônio por mês (1956–1970).

Mês	Média	DP	Mediana	Min	Max	<i>n</i>
Janeiro	3,03	1,18	2,80	2,00	6,60	15
Fevereiro	3,34	0,75	3,20	2,30	4,50	15
Março	3,65	0,86	3,70	2,60	5,40	15
Abril	4,56	1,18	4,80	1,60	6,00	15
Maio	5,47	1,16	5,20	3,90	8,30	15
Junho	6,60	1,16	6,50	4,40	8,10	15
Julho	8,21	0,86	8,60	6,50	9,50	15
Agosto	7,91	1,03	7,70	6,20	9,30	15
Setembro	6,73	0,89	6,90	4,90	8,10	15
Outubro	5,29	1,05	5,10	3,80	7,90	15
Novembro	3,53	0,78	3,60	2,30	4,80	15
Dezembro	2,63	0,65	2,60	1,60	3,90	15


A Figura 2.1 apresenta o comportamento da série ao longo do tempo, onde o padrão sazonal cíclico é evidente.

Figura 2.1: Gráfico da Série Temporal de Níveis de Ozônio (1956-1970).



Para investigar a variabilidade mensal, foi construído um boxplot (Figura 2.2), que reforça a presença de um forte padrão sazonal, com a mediana e a dispersão dos dados variando consistentemente ao longo dos meses.


Figura 2.2: Boxplot dos níveis de ozônio por mês.



2.2 Decomposição da Série

Para analisar os componentes da série de forma isolada, foi aplicada uma decomposição multiplicativa, cujos resultados são exibidos na Figura 2.3.

Figura 2.3: Decomposição Multiplicativa da Série Temporal.



A análise da Figura 2.3 revela:

- **Tendência:** O componente de tendência mostra uma leve inclinação ascendente e decrescente ao longo do período, indicando uma variação nos níveis de ozônio.
- **Sazonalidade:** O componente sazonal é muito pronunciado e regular, confirmando o padrão de picos e vales anuais já observado.
- **Erro:** O componente de erro (resíduo) parece ser estacionário, flutuando em torno de 1 sem um padrão claro, o que é desejável.

2.3 Testes Formais na Série Original

Para formalizar as observações visuais, foram aplicados testes estatísticos.

2.3.1 Teste para Estacionariedade

A combinação dos testes de Dickey-Fuller Aumentado (ADF) e Kwiatkowski-Phillips-Schmidt-Shin (KPSS) indicou que a série original é estacionária (valor- p do ADF $< 0,05$ e do KPSS $> 0,05$). No entanto, após a aplicação de uma diferenciação sazonal (Δ_{12}), a série continuou estacionária.

2.3.2 Teste para Tendência

O teste de Mann-Kendall foi aplicado para verificar a presença de tendência monotônica. O resultado não apontou uma tendência estatisticamente significativa, sugerindo que o componente de tendência observado na decomposição não é forte o suficiente para ser considerado monotonicamente crescente ou decrescente.

2.3.3 Teste para Sazonalidade

O teste QS (*Quadratic Spectral*) resultou em um valor- p muito baixo ($< 0,01$), rejeitando a hipótese nula de ausência de sazonalidade e confirmando formalmente a forte presença do componente sazonal.

3 Metodologia Box-Jenkins: Identificação, Estimação e Diagnóstico

Neste capítulo, detalha-se a construção do modelo SARIMA, que é adequado para séries com sazonalidade estocástica. A forma geral de um modelo SARIMA(p, d, q)(P, D, Q) $_s$ é:


$$\phi_p(B)\Phi_P(B^s)(1-B)^d(1-B^s)^D Z_t = \theta_q(B)\Theta_Q(B^s)a_t \quad (3.1)$$

onde B é o operador de defasagem e $a_t \sim RB(0, \sigma_a^2)$ é um ruído branco.

3.1 Identificação dos Parâmetros

A análise das funções de Autocorrelação (ACF) e Autocorrelação Parcial (PACF) da série original (Figura 3.1) foi o ponto de partida para a identificação.

Figura 3.1: ACF e PACF da série original de ozônio.



O ACF exibe um decaimento lento e senoidal, com picos significativos nos lags sazonais (12, 24, ...), reforçando a necessidade de diferenciação sazonal ($D = 1$). O PACF mostra um pico significativo no lag 1, sugerindo um componente autorregressivo de ordem 1 ($p = 1$). Os picos nos lags sazonais do ACF e PACF sugerem também componentes sazonais de médias móveis ou autorregressivos.


3.2 Diagnóstico dos Modelos

Com base na análise inicial, foram propostos e ajustados dois modelos.

3.2.1 Modelo 1: SARIMA(1,0,0)(0,1,1)₁₂

Este modelo inicial foi ajustado com base nas principais características observadas no ACF/PACF. A análise de seus resíduos (Figura 3.2) revelou um problema.

Figura 3.2: Diagnóstico dos resíduos (ACF e PACF) para o Modelo 1.




Embora muitas autocorrelações tenham sido removidas, observa-se uma **correlação residual significativa no lag 9**, tanto no ACF quanto no PACF. Isso indica que o modelo não capturou toda a estrutura de dependência temporal dos dados.

3.2.2 Modelo 2: SARIMA(1,0,9)(0,1,1)₁₂ com Parâmetros Fixos

Para corrigir a deficiência do Modelo 1 de forma parcimoniosa, foi ajustado um segundo modelo que lida especificamente com o lag 9. Utilizou-se o argumento `fixed` para estimar apenas os coeficientes de interesse (`ar1`, `ma9`, `sma1`), forçando os demais a zero.


Análise de resíduos. A análise de resíduos do Modelo 2 (Figuras 3.3, 3.4 e 3.5) demonstra a adequação do modelo.

Figura 3.3: Diagnóstico dos resíduos (ACF e PACF) para o Modelo 2.




Os gráficos de ACF e PACF dos resíduos (Figura 3.3) agora não mostram nenhuma autocorrelação significativa, comportando-se como um ruído branco.

Figura 3.4: Valores-p para o Teste de Ljung-Box - Modelo 2.



O teste de Ljung-Box (Figura 3.4) corrobora essa conclusão, com todos os valores- p acima do nível de significância de 5%, indicando a ausência de autocorrelação serial nos resíduos.

Figura 3.5: Q-Q Plot dos resíduos – Modelo 2.



Finalmente, o Q-Q Plot (Figura 3.5) mostra que os resíduos se aderem bem à linha de normalidade. O teste de Shapiro-Wilk resultou em um valor- p de 0,4574, não rejeitando a hipótese de normalidade.

4 Escolha do Modelo Ideal e Previsão

4.1 Análise Comparativa dos Resultados

A Tabela 4.1 compara os dois modelos com base em critérios de ajuste e parcimônia.

Tabela 4.1: Resumo comparativo dos indicadores para os modelos candidatos.


Critério	Modelo 1	Modelo 2 (Final)
<i>Ajuste e Parcimônia</i>		
Log-Verossimilhança (ℓ)	-248,16	-245,86
AIC	502,31	499,72
AICc	502,46	499,97
BIC	511,68	512,22
Variância dos Resíduos ($\hat{\sigma}^2$)	1,028	1,004
<i>Diagnóstico dos Resíduos</i>		
Autocorrelação no Lag 9	Não Significativa	Não Significativa

O Modelo 2 é superior em todos os aspectos: possui maior log-verossimilhança, menores valores de AIC, AICc e BIC (indicando melhor ajuste penalizado pela complexidade) e menor variância dos resíduos. Mais importante, ele resolve o problema de autocorrelação residual presente no Modelo 1. Portanto, o Modelo 2 é escolhido como o modelo final.

4.2 Previsão

Utilizando o Modelo 2, foram geradas previsões para os próximos 12 meses. A Figura 4.1 mostra as previsões junto com os dados históricos.

Figura 4.1: Previsões para os próximos 12 meses com o Modelo 2.



As previsões capturam bem o padrão sazonal da série, projetando um ciclo anual consistente com o comportamento histórico. Os intervalos de confiança (áreas sombreadas) fornecem uma faixa plausível para os valores futuros.

5 Apêndice A

5.1 Lista de Códigos

Script completo dos códigos utilizados

```
# -----
# 1. CONFIGURAÇÃO INICIAL E CARREGAMENTO DOS DADOS
# -----

#
library(fpp2)
library(tseries)
library(readxl)
library(Kendall)
library(scales)
library(ggplot2)

# Carregando os dados (assumindo que o arquivo "A4-
#   OZONIO.XLS" está no diretório)
dados <- read_excel("C:/Users/dougl/Downloads/A4-OZONIO.XLS",
  col_types = c("text", "numeric", "numeric"))

# Criando o objeto de série temporal (ts)
serie_ozonio <- ts(dados$Ozonio, start = c(1956, 1),
  frequency = 12)

# -----
# 2. ANÁLISE EXPLORATÓRIA E TESTES DE HIPÓTESES
# -----

# Visualização inicial da série
autoplot(serie_ozonio, lwd = 2) +
```

```

# ggtitle("Série Temporal de Níveis de Ozônio (1956-1970)
  ") +
xlab("Ano") +
ylab("Nível de Ozônio") +
theme_bw()

# Decomposição (para análise visual)
decomposicao <- decompose(serie_ozonio, type = "
  multiplicative")
plot(decomposicao)

# Boxplot sazonal
boxplot(serie_ozonio ~ cycle(serie_ozonio),
        # main = "Boxplot Mensal dos Níveis de Ozônio
        (1956-1970) ",
        xlab = "Mês", ylab = "Nível de Ozônio")

# -- Testes de Estacionariedade (série original) --
cat("\n=== TESTE DE ESTACIONARIEDADE (SÉRIE ORIGINAL) ===\n
  ")
# H0: série não é estacionária
adf.test(serie_ozonio)
# H0: série é estacionária
kpss.test(serie_ozonio)
# Conclusão: A combinação dos testes sugere
  estacionariedade.

# -- Testes de Tendência --
cat("\n=== TESTES DE TENDÊNCIA ===\n")
# H0: não há tendência
MannKendall(serie_ozonio)
tempo <- 1:length(serie_ozonio)
summary(lm(serie_ozonio ~ tempo))
# Conclusão: Não há evidência de tendência monotônica.

# -- Teste de Sazonalidade --
cat("\n=== TESTE DE SAZONALIDADE ===\n")

```

```

# H0: não há sazonalidade
qs(serie_ozonio, freq = frequency(serie_ozonio))
# Conclusão: Existe sazonalidade significativa.

# -- Análise de Variabilidade (Transformação Log) --
cat("\n=== ANÁLISE DE VARIABILIDADE ===\n")
cat("Variância da série original:", var(serie_ozonio), "\n"
    )
cat("Variância do log da série:", var(log(serie_ozonio)), "\n"
    )
# Conclusão: Ganho não é relevante. Manter série original
  pela interpretabilidade.

# -- Análise das Diferenças para tornar estacionária --
# Primeira diferença não sazonal (d=1)
adf.test(diff(serie_ozonio))
kpss.test(diff(serie_ozonio))
# Primeira diferença sazonal (D=1)
adf.test(diff(serie_ozonio, lag = 12))
kpss.test(diff(serie_ozonio, lag = 12))
# Conclusão: Ambas as diferenciações são eficazes.

# -----
# 3. IDENTIFICAÇÃO E ESTIMAÇÃO DO MODELO SARIMA
# -----

# Análise ACF/PACF da série original para guiar a modelagem
ggtsdisplay(serie_ozonio)#, main="ACF/PACF da Série
  Original")
# Observações: Forte padrão sazonal. Decaimento lento no
  ACF. PACF com pico no lag 1.
# Sugere SARIMA(1,d,q) (P,D,Q) [12] com D=1.

# -- Modelo 1: Primeira tentativa --
modelo.1 <- Arima(serie_ozonio,
                  order = c(1,0,0),

```

```

        seasonal = c(0,1,1),
        include.drift = FALSE)
summary(modelo.1)
ggtsdisplay(modelo.1\\$residuals) #, main="Resíduos do Modelo
  1")
# Diagnóstico: Resíduos mostram autocorrelação
  significativa no lag 9.

# -- Modelo 2: Modelo final com ajuste fino --
# Para corrigir o lag 9, adicionamos um MA(9) mas fixando
  os termos
# intermediários (ma2 a ma8) em zero para um modelo mais
  parcimonioso.
modelo.2 <- Arima(serie_ozonio,
                  order = c(1,0,9),
                  seasonal = c(0,1,1),
                  fixed = c(NA, 0,0,0,0,0,0,0,0, NA, NA))
# fixed = c(ar1, ma1, ma2, ma3, ma4, ma5, ma6, ma7, ma8,
  ma9, sma1)
# NA = estimar; 0 = fixar em zero.

summary(modelo.2)
ggtsdisplay(modelo.2\\$residuals) #, main="Resíduos do Modelo
  2 (Final)"
# Diagnóstico: ACF/PACF dos resíduos agora parecem ruído
  branco.

# -----
# 4. DIAGNÓSTICO DO MODELO FINAL (MODELO 2)
# -----

# Teste de Ljung-Box para diferentes lags
ljung_box_plot <- function(residuos, max_lag = 50) {
  ljung_p <- numeric(max_lag)
  for (i in 1:max_lag) {
    ljung_p[i] <- Box.test(residuos, lag = i, type = "Ljung

```

```

-Box")\ $p.value
}

# Criando o dataframe para o ggplot
df_ljung <- data.frame(
  Lag = 1:max_lag,
  P_Value = ljung_p
)

# Usando ggplot para criar o gráfico
library(ggplot2)
ggplot(df_ljung, aes(x = Lag, y = P_Value)) +
  geom_point(size = 3, color = "black") + # Pontos
  geom_hline(yintercept = 0.05, color = "blue", linetype
= "dashed", linewidth = 1.5) + # Linha de referência
  scale_x_continuous(breaks = seq(6, max_lag, by = 6)) +
  # Ajusta os rótulos do eixo X
  scale_y_continuous(labels = label_comma(big.mark = ".",
decimal.mark = ",")) +
  labs(
    title = "",
    x = "Lag",
    y = "Valor-p"
  ) +
  theme_bw(base_size = 18) + # Tema base
  theme(
    panel.grid.minor = element_blank(),
    axis.title = element_text(face = "bold", size = 22),
    axis.text = element_text(size = 22),
    plot.title = element_text(face = "bold", size = 20,
hjust = 0.5)
  )
}

# A hipótese nula ( $H_0$ ) é que os resíduos são independentes.
# Queremos um p-valor alto (ex:  $> 0.05$ ) para não rejeitar
 $H_0$ .
ljung_box_plot(modelo.2\ $residuals)

```

```

# Conclusão: Todos os p-valores estão acima de 0.05. Os res
  íduos são independentes.

# -- Diagnóstico completo com checkresiduals --
checkresiduals(modelo.2)

# -- Teste de Normalidade dos Resíduos --
# H0: Resíduos são normalmente distribuídos.
shapiro.test(modelo.2$residuals)
# Conclusão: p-valor (0.4574) > 0.05. Não se rejeita H0.
  Resíduos são normais.

# Verificação visual da normalidade com Gráfico Q-Q
qqnorm(modelo.2$residuals, main="", lwd = 3)
qqline(modelo.2$residuals, col = "blue", lwd = 4)

# -----
# 5. PREVISÃO
# -----

# Gerar previsões para os próximos 12 meses
previsao_modelo.2 <- forecast(modelo.2, h = 12)

# Visualizar as previsões com a série original
autoplot(serie_ozonio, linewidth = 2) +
  autolayer(previsao_modelo.2, series = "Previsão", PI =
    TRUE, linewidth = 2) +
  #ggtitle("Previsões com o Modelo SARIMA Final") +
  xlab("Ano") +
  ylab("Nível de Ozônio") +
  guides(colour=guide_legend(title="Séries")) +
  theme_bw()

```

Referências Bibliográficas

MORETTIN, P. A.; TOLOI, C. M. C. **Análise de séries temporais**. 2. ed. São Paulo: Blucher, 2006.

Posit team. **RStudio: Integrated Development Environment for R**. Boston, MA, 2024. RStudio version 2024.12.0+467, "Kousa Dogwood". Disponível em: <<http://www.posit.co/>>.

R Core Team. **R: A Language and Environment for Statistical Computing**. Vienna, Austria, 2024. R version 4.4.2 (2024-10-31). Disponível em: <<https://www.R-project.org/>>.