



UNIVERSIDADE FEDERAL DO CEARÁ
CENTRO DE CIÊNCIAS
DEPARTAMENTO DE ESTATÍSTICA E MATEMÁTICA APLICADA
CURSO DE GRADUAÇÃO EM ESTATÍSTICA

DOUGLAS CHAVES MOURA

Primeira prova prática - Séries Temporais

FORTALEZA

2025

DOUGLAS CHAVES MOURA

Primeira prova prática - Séries Temporais

Trabalho apresentado à disciplina Análise de Séries Temporais, do curso de Graduação em Estatística do Centro de Ciências da Universidade Federal do Ceará, como parte dos requisitos para a avaliação da referida disciplina, no semestre 2025.1.

Professora: Dr^a Jeniffer Johana Duarte Sanchez

FORTALEZA

2025

Lista de Figuras

2.1	Gráfico da Série Temporal.	3
2.2	Histograma da variação percentual com densidade ajustada.	3
2.3	Boxplot da variação percentual dos gastos por trimestre.	4
2.4	Decomposição da Série Temporal.	5
3.1	Função de Autocorrelação.	7
3.2	Função de Autocorrelação Parcial.	8
3.3	Diagnóstico dos resíduos (ACF) para o modelo ARIMA(3,0,0).	9
3.4	Diagnóstico dos resíduos (PACF) para o modelo ARIMA(3,0,0).	10
3.5	Comportamento dos resíduos - Modelo ARIMA(3,0,0).	11
3.6	valores- p para o Teste de Ljung-Box - Modelo ARIMA(3,0,0).	11
3.7	Q-Q plot dos resíduos – ARIMA(3,0,0).	12
3.8	Diagnóstico dos resíduos (ACF) para o modelo ARIMA(0,0,3).	13
3.9	Diagnóstico dos resíduos (PACF) para o modelo ARIMA(0,0,3).	13
3.10	Comportamento dos resíduos - Modelo ARIMA(0,0,3).	14
3.11	valores- p para o Teste de Ljung-Box - Modelo ARIMA(0,0,3).	14
3.12	Q-Q plot dos resíduos – ARIMA(3,0,0).	15
3.13	Diagnóstico dos resíduos (ACF) para o modelo ARIMA(3,0,3).	16
3.14	Diagnóstico dos resíduos (PACF) para o modelo ARIMA(3,0,3).	17
3.15	Comportamento dos resíduos - Modelo ARIMA(3,0,3).	17
3.16	valores- p para o Teste de Ljung-Box - Modelo ARIMA(3,0,3).	18
3.17	Q-Q plot dos resíduos – ARIMA(3,0,3).	18

Lista de Tabelas

2.1	Estatísticas descritivas da variação percentual nos gastos de consumo pessoal. .	2
2.2	Estatísticas descritivas da variação percentual nos gastos de consumo pessoal por trimestre (1970–2016).	2
4.1	Resumo comparativo dos indicadores de ajuste, precisão e diagnóstico para os modelos candidatos. O melhor desempenho em cada critério está destacado em negrito.	20
4.2	Medidas de erro dos modelos ajustados.	21

Sumário

Lista de Figuras

Lista de Tabelas

1	Introdução	1
2	Análise Exploratória e Descritiva	2
2.1	Descrição e Visualização dos Dados	2
2.2	Decomposição da Série	4
2.3	Testes Formais na Série Original	5
2.3.1	Teste para Estacionariedade	6
2.3.2	Teste para Tendência	6
2.3.3	Teste para Sazonalidade	6
3	Metodologia Box-Jenkins: Identificação, Estimação e Diagnóstico	7
3.1	Identificação dos Parâmetros (p,d,q)	7
3.2	Diagnóstico dos Modelos	8
3.2.1	Modelo ARIMA(3,0,0) – AR(3)	9
3.2.2	Modelo ARIMA(0,0,3) - MA(3)	12
3.2.3	Modelo ARIMA(3,0,3) - ARMA(3,3)	15
4	Escolha do Modelo Ideal	20
4.1	Análise Comparativa dos Resultados	20
5	Conclusão	22
6	Apêndice A	23
6.1	Lista de Códigos	23
	Referências Bibliográficas	33

1 Introdução

O seguinte trabalho busca analisar um conjunto de dados por meio da metodologia de Séries Temporais. O objetivo é identificar a estrutura estocástica da série, ajustar um modelo preditivo adequado e realizar previsões.

A base de todo o desenvolvimento metodológico foi coletada do livro "Análise de Séries Temporais" de [Morettin e Tolo \(2006\)](#), além dos conceitos vistos em sala de aula. A metodologia principal a ser seguida é a de Box-Jenkins para modelos ARIMA.

Toda a aplicação será desenvolvida no software R (Versão 4.4.2) ([R Core Team, 2024](#)), através da IDE (Integrated Development Environment) RStudio (Versão 2024.12.0.467) ([Posit team, 2024](#)).

2 Análise Exploratória e Descritiva

2.1 Descrição e Visualização dos Dados

A série temporal em estudo refere-se à variação percentual trimestral dos gastos de consumo pessoal, iniciando no ano de 1970 e encerrando-se em 2016, totalizando 187 observações. Trata-se, portanto, de uma série temporal discreta (registrada a cada trimestre) e univariada. As principais estatísticas descritivas da variável estão apresentadas na Tabela 2.1.

Tabela 2.1: Estatísticas descritivas da variação percentual nos gastos de consumo pessoal.

Variável	Média	DP	EP	Mediana	Assimetria	Curtose	Min	Max	<i>n</i>
Variação (%)	0,75	0,66	0,05	0,77	-0,79	2,55	-2,27	2,32	187


Considerando que a série é trimestral, as estatísticas descritivas também foram analisadas separadamente por trimestre, conforme apresentado na Tabela 2.2.

Tabela 2.2: Estatísticas descritivas da variação percentual nos gastos de consumo pessoal por trimestre (1970–2016).

Trimestre	Média	DP	EP	Mediana	Assimetria	Curtose	Min	Max	Amplitude	<i>n</i>
1º Trimestre	0,74	0,62	0,09	0,62	0,00	0,05	-0,88	1,98	2,86	47
2º Trimestre	0,71	0,72	0,10	0,73	-1,18	4,58	-2,27	2,11	4,39	47
3º Trimestre	0,85	0,47	0,07	0,79	-0,15	1,33	-0,72	1,90	2,63	47
4º Trimestre	0,69	0,78	0,12	0,82	-0,72	0,39	-1,48	2,32	3,79	46

A Figura 2.1 apresenta o gráfico da série temporal.


Figura 2.1: Gráfico da Série Temporal.



Visualmente, observa-se um comportamento aproximadamente estacionário ao longo do tempo, com a média da variação percentual oscilando em torno de um valor entre 0 e 1. No entanto, é perceptível uma variação acentuada entre os trimestres de alguns anos — especialmente durante as décadas de 1970 e 1980, onde ocorreram quedas mais bruscas.

A distribuição empírica da série é apresentada por meio do histograma da Figura 2.2.


Figura 2.2: Histograma da variação percentual com densidade ajustada.



Nota-se que os dados não seguem uma distribuição perfeitamente simétrica, havendo observações dispersas nas caudas — especialmente na cauda inferior — o que sugere leve assimetria negativa e possíveis *outliers*.

Para investigar a variabilidade entre os trimestres, foi construído um boxplot da variável de interesse separado por trimestre (Figura 2.3).

Figura 2.3: Boxplot da variação percentual dos gastos por trimestre.




As medianas trimestrais são relativamente próximas, mas a dispersão varia entre os períodos. Em todos os trimestres foram identificadas observações consideradas *outliers*, reforçando a presença de valores atípicos ao longo da série.

2.2 Decomposição da Série

Para analisar melhor as suposições, vamos decompor a série em seus componentes.

Nesta etapa vamos separar a série temporal em partes para vermos o seu comportamento de maneira mais clara, para isso decompos a série em seus componentes de tendência, sazonalidade e resíduo.

Figura 2.4: Decomposição da Série Temporal.



Através da visualização da figura 2.4 observamos no primeiro “sub-gráfico” os valores da série - assim como na figura 2.1.

Já no segundo “sub-gráfico” vemos o comportamento separado da tendência da série, onde observa-se uma característica de oscilação com amplitude considerável, principalmente nas décadas de 1970 e 1980.

No terceiro “sub-gráfico” têm-se a sazonalidade da série que de modo geral não tem muito destaque.

Por fim, o último “sub-gráfico” mostra o componente de erro da série - no caso da decomposição aditiva $Y_t = T_t + S_t + \varepsilon_t$, sendo T_t : o componente de Tendência; S_t : o componente Sazonal; e ε_t : o que sobra após a remoção da tendência e da sazonalidade - que apresenta somente uma parte aleatória maior para alguns trimestres das décadas que já havíamos destacado, nada muito preocupante.

2.3 Testes Formais na Série Original

Para essa etapa, vamos formalizar as primeiras ideias que havíamos comentado através da análise visual feita anteriormente. Iremos confirmar ou não a presença de estacionariedade, tendência e sazonalidade com alguns testes estatísticos próprios para cada um.

2.3.1 Teste para Estacionariedade

A série original é estacionária, os testes de Dickey-Fuller Aumentado (ADF) têm como resultado do valor- p igual a 0,01 fazendo-nos rejeitar a hipótese nula da série ter raiz unitária, logo, estacionária.

O teste de Kwiatkowski-Phillips-Schmidt-Shin (KPSS) também reforça esse resultado, testando se a série é estacionária em torno de uma média (ou tendência) e não rejeitando essa hipótese - com valor- $p > 5\%$.

2.3.2 Teste para Tendência

Pelo teste de tendência monotônica da série - Mann-Kendall, temos um indicativo de haver sim uma tendência de caráter negativo - através do resultado $\tau = -0,141$ do teste, e um valor- p bem inferior ao nível de significância de 5%. Já o teste de Regressão Linear Simples para Tendência também evidencia um valor- p menor que 5% para o termo “tempo” (por mais que não seja muito significativo), rejeita-se a hipótese de não haver tendência.

2.3.3 Teste para Sazonalidade

Já para o teste de sazonalidade QS (*Quadratic Spectral*) temos um valor- p igual a 1 (um), evidenciando uma forte característica de não haver sazonalidade. Como visto na figura 2.4, na parte que mostra a decomposição da série em sazonalidade, não temos essa característica nesta série temporal.

3 Metodologia Box-Jenkins: Identificação, Estimação e Diagnóstico

3.1 Identificação dos Parâmetros (p,d,q)

Como nos testes iniciais mostraram uma variabilidade alta, idealmente era utilizar-se da transformação logarítmica, mas como existem valores muito próximos de zero da variável de estudo não podemos seguir com essa abordagem.

Mesmo não havendo a necessidade de usar a diferenciação - pois a série já é estacionária - vamos mesmo assim comparar a variância da série original com a primeira diferença.

O resultado da variância da série original foi de $\approx 0,43$, já a variância da série quando feita a primeira diferença aumentou para $\approx 0,56$. Portanto, iremos continuar trabalhando com a série temporal original, sem nenhuma transformação nem diferenciação.

Análise ACF e PACF para identificar p e q. Com a série estacionária, analisamos seus gráficos de Autocorrelação (ACF) e Autocorrelação Parcial (PACF) para identificar as ordens p do modelo Auto-Regressivo (AR) e q do modelo de Médias Móveis (MA).

Figura 3.1: Função de Autocorrelação.





Figura 3.2: Função de Autocorrelação Parcial.



Através do gráfico da função de autocorrelação (3.1) vemos um decaimento senoidal com autocorrelação significativa (acima do limiar de decisão) para os 3 primeiros lags (1º trimestre) - o 4º lag está muito próximo do limite. Depois de um tempo, o lag 22 também mostra uma autocorrelação significativa - embora não seja muito “expressiva”.

Já no gráfico da função de autocorrelação parcial (3.2) têm-se um comportamento semelhante ao gráfico da autocorrelação. Existe autocorrelação parcial para os 3 primeiros lags, também com decaimento sazonal, e depois volta a ter o lag 22 ultrapassando um pouco o limiar de decisão.

Como o decaimento da série se comporta de modo senoidal para os gráficos ACF e PACF podemos pensar inicialmente em um modelo AR(3), MA(3) e também um ARMA(3,3). Essas três ideias iniciais de modelo englobam, de modo geral, as características observadas da série - sobre variação percentual nos gastos de consumo pessoal - nos gráficos de autocorrelação e autocorrelação parcial.

3.2 Diagnóstico dos Modelos

Para os diagnósticos, utilizamos os modelos Auto-regressivos Integrados de Médias Móveis (ARIMA), que modelam a estrutura de dependência temporal de uma série. De modo geral, um modelo ARIMA(p, d, q) é representado por:

$$\phi(B)\Delta^d Z_t = \theta(B)a_t + \delta_0, \quad a_t \sim \text{RB}(0, \sigma_a^2), \quad (3.1)$$

com p e q representando as ordens do modelo auto-regressivo (AR) e de médias móveis (MA), respectivamente, e d a ordem de diferenciação necessária para tornar a série estacionária. O operador de defasagem B é tal que $BZ_t = Z_{t-1}$.

3.2.1 Modelo ARIMA(3,0,0) – AR(3)

Como primeiro modelo, ajustamos um modelo auto-regressivo de ordem 3, ou seja, um ARIMA(3,0,0), dado por:

$$\begin{aligned}\phi(B)\Delta^0 Z_t &= \theta(B)a_t + \delta_0 \\ (1 - \phi_1 B - \phi_2 B^2 - \phi_3 B^3)Z_t &= a_t + \delta_0 \\ Z_t &= \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \phi_3 Z_{t-3} + a_t + \delta_0\end{aligned}$$

sendo a_t o ruído branco, δ_0 o termo constante, e os ϕ_j os coeficientes auto-regressivos.

A estimação dos parâmetros resultou em:

$$Z_t = 0,2274 \cdot Z_{t-1} + 0,1604 \cdot Z_{t-2} + 0,2027 \cdot Z_{t-3} + a_t + 0,7449, \quad a_t \sim \text{RB}(0, \sigma_a^2). \quad (3.2)$$

com $\sigma_a^2 = 0,3419$. Todos os coeficientes são significativos ao nível de 5%, com erros-p < 0,001.

Análise de resíduos Para verificar a adequação do modelo, analisamos os resíduos estimados. O objetivo é avaliar se estes se comportam como ruído branco, ou seja, independentes, com média zero, variância constante e distribuição aproximadamente normal.

Figura 3.3: Diagnóstico dos resíduos (ACF) para o modelo ARIMA(3,0,0).





Figura 3.4: Diagnóstico dos resíduos (PACF) para o modelo ARIMA(3,0,0).



As figuras 3.3 e 3.4 mostram que, em geral, com o uso do modelo ARIMA(3,0,0) conseguimos retirar a autocorrelação dos resíduos nos *lags* iniciais da série, entretanto o *lag* 22 continua sendo significativo, ou seja, ainda existe autocorrelação entre *lags* desse valor. Nesse modelo temos também um novo *lag* (8) mostrando ser significativamente diferente de zero.

Apesar disso, o teste de Ljung-Box com 10 defasagens não rejeita a hipótese nula de ausência de autocorrelação (valor- $p = 0,7367$), o que sugere que, de forma global, o modelo é adequado.

Esse comportamento relatado se estende tanto para o gráfico de autocorrelação quanto para autocorrelação parcial.

Figura 3.5: Comportamento dos resíduos - Modelo ARIMA(3,0,0).






Figura 3.6: valores- p para o Teste de Ljung-Box - Modelo ARIMA(3,0,0).



O gráfico da Figura 3.5 mostra resíduos centrados em torno de zero, com variação aproximadamente constante, mas destaca-se a presença de um valor atípico negativo.

Figura 3.7: Q-Q plot dos resíduos – ARIMA(3,0,0).



O gráfico Q-Q plot da Figura 3.7 revela leve assimetria à esquerda e caudas mais pesadas, o que compromete a suposição de normalidade. Essa observação é corroborada pelos testes:

- **Shapiro-Wilk:** valor- $p = 3,41 \cdot 10^{-5} \Rightarrow$ rejeita a hipótese nula de normalidade;
- **Jarque-Bera:** valor- $p = 1,799 \cdot 10^{-14} \Rightarrow$ rejeita fortemente a hipótese nula de normalidade.

3.2.2 Modelo ARIMA(0,0,3) - MA(3)

A segunda proposta de modelagem consiste em um modelo de médias móveis de ordem 3, ou seja, um ARIMA(0,0,3) ou MA(3). A sua forma geral é:

$$\begin{aligned}\phi(B)\Delta^d Z_t &= \theta(B)a_t \\ (1-B)^0 Z_t &= (1 - \theta_1 B - \theta_2 B^2 - \theta_3 B^3)a_t + \delta_0 \\ Z_t &= a_t - \phi_1 a_{t-1} - \phi_2 a_{t-2} - \phi_3 a_{t-3} + \delta_0\end{aligned}$$

sendo a_t o ruído branco, δ_0 o termo constante, e os θ_j são os parâmetros do componente de médias móveis.

A estimação dos parâmetros via máxima verossimilhança forneceu o seguinte modelo ajustado:

$$Z_t = a_t - 0,2403 \cdot a_{t-1} - 0,2187 \cdot a_{t-2} - 0,2665 \cdot a_{t-3} + 0,7473 \quad (3.3)$$

com $\sigma_a^2 = 0,3464$. Todos os coeficientes do modelo foram estatisticamente significativos.

Análise de resíduos A adequação do modelo é verificada através da análise de seus resíduos, que devem se comportar como um processo de ruído branco.

Figura 3.8: Diagnóstico dos resíduos (ACF) para o modelo ARIMA(0,0,3).





Figura 3.9: Diagnóstico dos resíduos (PACF) para o modelo ARIMA(0,0,3).



As funções de autocorrelação (Figura 3.8) e autocorrelação parcial (Figura 3.9) dos resíduos mostram que o modelo MA(3) conseguiu capturar a maior parte da estrutura de dependência temporal da série. No entanto, similarmente ao que foi observado no modelo AR(3), ainda persiste uma correlação marginalmente significativa no *lag* 22, e uma nova correlação significativa surge no *lag* 8.

Com o uso do modelo ARIMA(0,0,3) conseguimos retirar a autocorrelação dos resíduos nos *lags* iniciais da série, entretanto o *lag* 22 continua sendo significativo, ou seja, ainda existe

autocorrelação entre *lags* desse valor. Nesse modelo temos também um novo *lag* mostrando ser significativo, sendo no *lag* 8.

Partindo para a análise de normalidade dos resíduos.

Figura 3.10: Comportamento dos resíduos - Modelo ARIMA(0,0,3).






Figura 3.11: valores-*p* para o Teste de Ljung-Box - Modelo ARIMA(0,0,3).



Apesar da presença dessas autocorrelações pontuais, a análise global indica um bom ajuste. O teste de Ljung-Box para as 10 primeiras defasagens resultou em um valor-*p* de 0,571, não rejeitando a hipótese nula de independência dos resíduos. A Figura 3.11 mostra que os

valores- p se mantêm acima do nível de significância de 5% para todas as defasagens testadas, sugerindo que, de forma geral, os resíduos não possuem autocorrelação serial.

Figura 3.12: Q-Q plot dos resíduos – ARIMA(3,0,0).



A análise da distribuição dos resíduos, contudo, revela problemas. O gráfico de resíduos ao longo do tempo (Figura 3.10) mostra que, embora centrados em zero, há presença de valores atípicos. O Q-Q plot (Figura 3.12) confirma o desvio da normalidade, com os pontos se afastando da linha de referência nas caudas, indicando uma distribuição com caudas mais pesadas (leptocúrtica) que a normal.

Esta observação visual é fortemente corroborada pelos testes de normalidade:

- **Shapiro-Wilk:** valor- $p = 2,073 \cdot 10^{-5} \Rightarrow$ rejeita a hipótese nula de normalidade;
- **Jarque-Bera:** valor- $p = 2,2 \cdot 10^{-16} \Rightarrow$ rejeita fortemente a hipótese nula de normalidade.

3.2.3 Modelo ARIMA(3,0,3) - ARMA(3,3)

Finalmente, o terceiro modelo proposto combina os componentes auto-regressivo e de médias móveis, resultando em um modelo ARMA(3,3) ou ARIMA(3,0,3). Sua forma geral é dada por:

$$\begin{aligned}
 \phi(B)\Delta^d Z_t &= \theta(B)a_t \\
 (1 - \phi_1 B - \phi_2 B^2 - \phi_3 B^3)(1 - B)^0 Z_t &= (1 - \theta_1 B - \theta_2 B^2 - \theta_3 B^3)a_t + \delta_0 \\
 Z_t &= \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \phi_3 Z_{t-3} \\
 &\quad + a_t - \phi_1 a_{t-1} - \phi_2 a_{t-2} - \phi_3 a_{t-3} + \delta_0
 \end{aligned} \tag{3.4}$$

Após o ajuste, a equação do modelo estimado é:

$$\begin{aligned} Z_t = & 0,5145 \cdot Z_{t-1} + 0,4530 \cdot Z_{t-2} - 0,3675 \cdot Z_{t-3} + a_t \\ & + 0,2769a_{t-1} + 0,3564a_{t-2} - 0,4576a_{t-3} + 0,7462 \end{aligned} \quad (3.5)$$

com variância estimada do ruído $\sigma_a^2 = 0,3382$.

Uma análise crucial neste ponto é a da significância dos parâmetros. Utilizando a regra de que a razão entre o coeficiente e seu erro-padrão deve ser aproximadamente maior que 2 em módulo, nota-se que a maioria dos coeficientes não é estatisticamente significativa ao nível de 5%. Apenas o parâmetro θ_3 e o intercepto δ_0 atendem a esse critério. Isso pode ser um indicativo de que o modelo está super-parameterizado.

Análise de resíduos Mesmo com a evidência de alta complexidade do modelo, a análise dos resíduos é realizada para completar o diagnóstico.

Figura 3.13: Diagnóstico dos resíduos (ACF) para o modelo ARIMA(3,0,3).





Figura 3.14: Diagnóstico dos resíduos (PACF) para o modelo ARIMA(3,0,3).



As Figuras 3.13 e 3.14 mostram que os resíduos do modelo ARMA(3,3) não apresentam autocorrelação significativa na maioria das defasagens. Notavelmente, a correlação no lag 8, que era um problema nos modelos anteriores, foi eliminada. Contudo, a correlação no lag 22 ainda permanece marginalmente significativa.

Figura 3.15: Comportamento dos resíduos - Modelo ARIMA(3,0,3).






Figura 3.16: valores- p para o Teste de Ljung-Box - Modelo ARIMA(3,0,3).



Do ponto de vista global, o modelo se saiu muito bem. O teste de Ljung-Box com 10 defasagens produziu um valor- p de 0,9109, o mais alto entre os modelos testados, indicando forte evidência a favor da hipótese de não autocorrelação dos resíduos.

Figura 3.17: Q-Q plot dos resíduos – ARIMA(3,0,3).



A suposição de normalidade dos resíduos, no entanto, continua a ser violada. O gráfico de resíduos (Figura 3.15) ainda exibe valores atípicos, e o Q-Q plot (Figura 3.17) mostra um claro descolamento da linha de normalidade nas caudas. Os testes formais confirmam a não normalidade:

- **Shapiro-Wilk:** valor- $p = 6,752 \cdot 10^{-5} \Rightarrow$ rejeita a hipótese nula de normalidade;
- **Jarque-Bera:** valor- $p = 2,476 \cdot 10^{-13} \Rightarrow$ rejeita fortemente a hipótese nula de normalidade.

4 Escolha do Modelo Ideal

Este capítulo realiza a análise comparativa final entre os modelos AR(3), MA(3) e ARMA(3,3) propostos para a série de consumo. A seleção do modelo mais adequado se baseará em um balanço criterioso entre a qualidade do ajuste, a precisão preditiva e o princípio da parcimônia, utilizando as seguintes métricas de avaliação:

- **Ajuste e Parcimônia:** Log-verossimilhança (ℓ), Critério de Informação de Akaike (AIC) e variância estimada dos resíduos ($\hat{\sigma}^2$).
- **Precisão Preditiva:** Erro Quadrático Médio (RMSE) e Erro Percentual Absoluto Médio (MAPE), como principais representantes das métricas de erro.
- **Diagnóstico de Resíduos:** Valor- p do teste de Ljung-Box para autocorrelação serial.

4.1 Análise Comparativa dos Resultados

Para permitir uma avaliação direta, os principais indicadores de desempenho de cada modelo foram consolidados na Tabela 4.1.

Tabela 4.1: Resumo comparativo dos indicadores de ajuste, precisão e diagnóstico para os modelos candidatos. O melhor desempenho em cada critério está destacado em negrito.

Critério	AR(3)	MA(3)	ARMA(3,3)
<i>Ajuste e Parcimônia</i>			
Log-Verossimilhança (ℓ)	-165,17	-166,38	-164,20
AIC	340,34	342,76	344,40
Variância dos Resíduos ($\hat{\sigma}^2$)	0,3419	0,3464	0,3382
<i>Precisão Preditiva</i>			
RMSE	0,5847	0,5886	0,5816
MAPE	171,02	202,57	169,47
<i>Diagnóstico dos Resíduos</i>			
Valor- p Ljung-Box (lag 10)	0,7367	0,5710	0,9109

Tabela 4.2: Medidas de erro dos modelos ajustados.

Modelo	ME	RMSE	MAE	MPE	MAPE	MASE
AR(3)	0,00110657	0,5847286	0,4294193	47,28	171,02	0,768040
MA(3)	-0,00004929	0,5885885	0,4319020	79,15	202,57	0,772480
ARMA(3,3)	0,00072688	0,5815776	0,4296033	54,59	169,47	0,768369

AR(3). Apresenta o menor critério de informação de Akaike (AIC) e o menor Erro Percentual Médio (MPE) entre os modelos testados, com apenas três parâmetros AR. Não exibe autocorrelação residual significativa para os diferentes valores- p do teste de Ljung-Box, mas não atende à suposição de normalidade. É o modelo mais parcimonioso entre os três.

MA(3). Tem o maior Erro Percentual Médio (MPE) e AIC acima do AR(3), sem ganhos claros. Mantém qualidade aceitável no Ljung-Box, mas tem o pior Erro Percentual Absoluto Médio (MAPE), sugerindo maior erro relativo em previsão. Como seus benefícios são limitados, tende a ser preterido.

ARMA(3,3). Obtém o menor Raiz do Erro Quadrático Médio (RMSE) e melhor valor para o Erro Percentual Absoluto Médio (MAPE), além de valores- p mais alto para diferentes *lags* no Ljung-Box. Em contrapartida, exige seis parâmetros (maior complexidade) e apresenta o maior AIC, indicando possível sobreajuste. Útil quando a prioridade é minimizar erro de previsão, mas menos favorável se o critério principal for parcimônia.

5 Conclusão

Com base nas evidências, o modelo **MA(3)** é superado pelos demais em quase todos os critérios relevantes (maior AIC, maior erro) e, portanto, é descartado. A decisão final recai entre o **AR(3)** e o **ARMA(3,3)**.

Se o objetivo é um balanço entre simplicidade e desempenho, o modelo **AR(3)** é preferível (menor AIC e poucos parâmetros).

Caso a prioridade absoluta seja reduzir o erro de previsão, o **ARMA(3,3)** pode ser escolhido, atento ao risco de sobreajuste.

6 Apêndice A

6.1 Lista de Códigos

Script completo dos códigos utilizados

```
# =====
# ANÁLISE DE SÉRIES TEMPORAIS
# Autor: Douglas Chaves Moura
# Data: 30 de Junho de 2025
# Descrição: Roteiro passo a passo para análise e modelagem
# de séries temporais usando a metodologia Box-Jenkins.
# =====

# 0. CONFIGURAÇÃO INICIAL ----

# Carregamento de bibliotecas
suppressPackageStartupMessages({
  library(fpp2)           # Dados e funções de forecast
  library(forecast)       # Funções principais para
  modelagem
  library(tseries)        # Testes estatísticos para séries
  temporais
  library(readxl)         # Leitura de arquivos Excel
  library(Kendall)        # Teste de Mann-Kendall
  library(randtests)      # Teste de Cox-Stuart
  library(seastests)      # Testes de sazonalidade
  library(dplyr)          # Manipulação de dados
  library(ggplot2)        # Gráficos
  library(psych)          # Estatísticas descritivas
})

# Configuração global de gráficos
configurar_graficos <- function() {
```

```

par(mfrow = c(1, 1),      # Define a dimensão da janela gráfica
    cex.axis = 2,          # Aumenta os números dos eixos
    cex.lab = 2.2,         # Aumenta os rótulos dos eixos (
xlab, ylab)
    cex.main = 2.7,        # Aumenta o título do gráfico
    lwd = 2.7,             # Aumenta a espessura das linhas
    mar = c(5, 5, 2, 2)) # Aumenta as margens (baixo,
                          esquerda, cima, direita)
}

configurar_graficos()

# 1. CARREGAMENTO E PREPARAÇÃO DOS DADOS ----

# Leitura dos dados
dados_consumo <- read_excel("C:/Users/dougl/Downloads/
    consumo.xlsx",
                           col_types = c("numeric"))

# Criação da série temporal
serie_consumo <- ts(dados_consumo[,x],
                    start = c(1970, 1),
                    end = c(2016, 3),
                    frequency = 4)

# Informações básicas da série
cat("=== INFORMAÇÕES BÁSICAS DA SÉRIE ===\n")
cat("Classe:", class(serie_consumo), "\n")
cat("Início:", start(serie_consumo), "\n")
cat("Fim:", end(serie_consumo), "\n")
cat("Frequência:", frequency(serie_consumo), "\n")
cat("Resumo estatístico:\n")
print(summary(serie_consumo))

# Estatísticas descritivas detalhadas
describe(serie_consumo)

```

```

describeBy(serie_consumo, cycle(serie_consumo))

# 2. ANÁLISE EXPLORATÓRIA ----

# Gráfico principal da série
autoplot(serie_consumo,
         lwd = 2, color = "black") +
  labs(y = "Variação dos gastos de consumo pessoal (por
    Trimestre)",
       x = "Tempo") +
  theme_bw(base_size = 18) +
  theme(
    panel.grid.minor = element_blank(),
    axis.title = element_text(face = "bold", size = 22),
    axis.text = element_text(size = 22),
    plot.title = element_text(face = "bold", size = 20,
    hjust = 0.5)
  )

# Decomposição da série
decomposicao_serie <- decompose(serie_consumo, type = "
  additive")
plot(decomposicao_serie)

# Análise de sazonalidade
ggseasonplot(serie_consumo,
             xlab = "Trimestre",
             ylab = "Variação percentual") +
  labs(title = "") +
  theme_bw(base_size = 18) +
  theme(
    legend.title = element_text(face = "bold", size = 20),
    legend.text = element_text(size = 20),
    legend.position = "bottom",
    legend.direction = "horizontal",
    legend.key.width = unit(1.5, "cm"),
    panel.grid.minor = element_blank(),

```

```

    axis.title = element_text(face = "bold", size = 22),
    axis.text = element_text(size = 22),
    plot.title = element_text(face = "bold", size = 20,
    hjust = 0.5)
) +
guides(colour = guide_legend(ncol = 7))

# Histograma e densidade
hist(serie_consumo, freq = FALSE,
     main = "",
     xlab = "Valores da série",
     ylab = "Densidade",
     col = "seagreen",
     lwd = 1.5)
lines(seq(min(serie_consumo), max(serie_consumo), length =
100),
      dnorm(seq(min(serie_consumo), max(serie_consumo),
length = 100),
            mean = mean(serie_consumo),
            sd = sd(serie_consumo))),
      col = "black", lwd = 4)

# Boxplot por trimestre
boxplot(serie_consumo ~ cycle(serie_consumo),
        main = "",
        xlab = "Trimestre",
        ylab = "Valores",
        col = "seagreen")

# 3. TESTES ESTATÍSTICOS ----

cat("\n=== TESTES DE ESTACIONARIEDADE ===\n")

# Teste de Dickey-Fuller Aumentado (ADF)
# H0: série possui raiz unitária (não estacionária)
# H1: série é estacionária
adf.test(serie_consumo)

```

```

# Teste de Kwiatkowski-Phillips-Schmidt-Shin (KPSS)
# H0: série é estacionária em torno de uma média ou tendê
ncia
# H1: série possui raiz unitária (não estacionária)
kpss.test(serie_consumo)

cat("\n=== TESTES DE TENDÊNCIA ===\n")

# Teste de Mann-Kendall
# H0: não há tendência monotônica na série
# H1: existe tendência monotônica
MannKendall(serie_consumo)

# Teste de Regressão Linear para Tendência
# H0: coeficiente de tendência igual a 0 (sem tendência)
# H1: coeficiente de tendência diferente de 0 (com tendê
ncia)
tempo <- 1:length(serie_consumo)
modelo_tendencia <- lm(serie_consumo ~ tempo)
summary(modelo_tendencia)

cat("\n=== TESTES DE SAZONALIDADE ===\n")

# Teste QS (Quadratic Spectral) para Sazonalidade
# H0: não há sazonalidade estável
# H1: existe sazonalidade estável
qs(serie_consumo, freq = frequency(serie_consumo))

# 4. ANÁLISE DE VARIABILIDADE ----

cat("\n=== ANÁLISE DE VARIABILIDADE ===\n")
cat("Variância da série original:", var(serie_consumo), "\n
")
cat("Variância da série diferenciada:", var(diff(serie_
consumo)), "\n")

```



```

# Nota: Transformação logarítmica não é possível devido a
valores próximos de zero

# 5. ANÁLISE DE AUTOCORRELAÇÃO ----

# Gráficos ACF e PACF usando ggplot2
ggAcf(serie_consumo) +
  labs(title = "") +
  theme_bw(base_size = 18) +
  theme(
    panel.grid.minor = element_blank(),
    axis.title = element_text(face = "bold", size = 22),
    axis.text = element_text(size = 22),
    plot.title = element_text(face = "bold", size = 20,
    hjust = 0.5)
  )

ggPacf(serie_consumo) +
  labs(title = "") +
  theme_bw(base_size = 18) +
  theme(
    panel.grid.minor = element_blank(),
    axis.title = element_text(face = "bold", size = 22),
    axis.text = element_text(size = 22),
    plot.title = element_text(face = "bold", size = 20,
    hjust = 0.5)
  )

# 6. MODELAGEM ARIMA ----

# Função para avaliação de modelos
avaliar_modelo <- function(modelo, nome_modelo) {
  cat("\n=== AVALIAÇÃO DO MODELO", nome_modelo, "===\n")
  print(summary(modelo))

  # Testes de diagnóstico
  cat("\n--- Teste de Ljung-Box ---\n")

```

```

print(Box.test(modelo\$residuals, lag = 10, type = "Ljung
-Box"))

cat("\n--- Teste de Jarque-Bera ---\n")
print(jarque.bera.test(modelo\$residuals))

cat("\n--- Teste de Shapiro-Wilk ---\n")
if(length(modelo\$residuals) <= 5000) {
  print(shapiro.test(modelo\$residuals))
} else {
  cat("Amostra muito grande para o teste de Shapiro-Wilk\
n")
}

return(modelo)
}

# Função para diagnóstico gráfico dos resíduos
diagnosticar_residuos <- function(modelo, nome_modelo) {
  # ACF dos resíduos
  ggAcf(modelo\$residuals) +
    labs(title = paste("ACF dos Resíduos -", nome_modelo))
  +
    theme_bw(base_size = 18) +
    theme(
      panel.grid.minor = element_blank(),
      axis.title = element_text(face = "bold", size = 22),
      axis.text = element_text(size = 22),
      plot.title = element_text(face = "bold", size = 20,
hjust = 0.5)
    )

  # PACF dos resíduos
  ggPacf(modelo\$residuals) +
    labs(title = paste("PACF dos Resíduos -", nome_modelo))
  +
    theme_bw(base_size = 18) +

```

```

theme(
  panel.grid.minor = element_blank(),
  axis.title = element_text(face = "bold", size = 22),
  axis.text = element_text(size = 22),
  plot.title = element_text(face = "bold", size = 20,
hjust = 0.5)
)

# Histograma dos resíduos
hist(modelo$residuals, freq = FALSE,
      main = paste("Distribuição dos Resíduos -", nome_
modelo),
      xlab = "Resíduos",
      ylab = "Densidade",
      col = "seagreen",
      lwd = 1.5,
      breaks = 30)
lines(seq(min(modelo$residuals), max(modelo$residuals),
length = 100),
      dnorm(seq(min(modelo$residuals), max(modelo$
residuals), length = 100),
            mean = mean(modelo$residuals),
            sd = sd(modelo$residuals))),
      col = "black", lwd = 4)

# Q-Q plot
qqnorm(modelo$residuals, main = paste("Q-Q Plot -", nome
_modelo),
       xlab = "Quantis Teóricos", ylab = "Quantis
Amostrais", lwd = 3)
qqline(modelo$residuals, col = "seagreen", lwd = 4)

# Teste de Ljung-Box para diferentes lags
ljung_box_plot <- function(residuos, max_lag = 25) {
  ljung_p <- numeric(max_lag)
  for (i in 1:max_lag) {
    ljung_p[i] <- Box.test(residuos, lag = i, type = "

```

```

Ljung-Box")\ $p.value
}

plot(1:max_lag, ljung_p, type = "b", lwd = 3,
     ylim = c(0, 1),
     main = paste("Teste de Ljung-Box -", nome_modelo),
     xlab = "Lag", ylab = "Valor-p")
abline(h = 0.05, col = "blue", lty = 2)
}

ljung_box_plot(modelo\ $residuals)
}

# Ajuste dos modelos candidatos
cat("\n=== AJUSTE DE MODELOS ===\n")

# Modelo AR(3)
modelo_ar3 <- arima(serie_consumo, order = c(3, 0, 0))
modelo_ar3 <- avaliar_modelo(modelo_ar3, "AR(3)")
diagnosticar_residuos(modelo_ar3, "AR(3)")

# Modelo MA(3)
modelo_ma3 <- arima(serie_consumo, order = c(0, 0, 3),
                    include.mean = TRUE)
modelo_ma3 <- avaliar_modelo(modelo_ma3, "MA(3)")
diagnosticar_residuos(modelo_ma3, "MA(3)")

# Modelo ARMA(3,3)
modelo_arma33 <- arima(serie_consumo, order = c(3, 0, 3))
modelo_arma33 <- avaliar_modelo(modelo_arma33, "ARMA(3,3)")
diagnosticar_residuos(modelo_arma33, "ARMA(3,3)")

# Modelo automático
modelo_auto <- auto.arima(serie_consumo,
                          seasonal = FALSE,
                          stepwise = FALSE,
                          approximation = FALSE,

```

```

                                d = 0)
modelo_auto <- avaliar_modelo(modelo_auto, "AUTO")

# 7. COMPARAÇÃO DE MODELOS ----

modelos <- list(
  "AR(3)" = modelo_ar3,
  "MA(3)" = modelo_ma3,
  "ARMA(3,3)" = modelo_arma33,
  "AUTO" = modelo_auto
)

# Critérios de informação
criterios <- data.frame(
  Modelo = names(modelos),
  AIC = sapply(modelos, AIC),
  BIC = sapply(modelos, BIC),
  stringsAsFactors = FALSE
)

cat("\n=== COMPARAÇÃO DE MODELOS ===\n")
print(criterios)

# Melhor modelo por AIC
melhor_modelo <- modelos[[which.min(criterios$AIC)]]
cat("\nMelhor modelo por AIC:", criterios$Modelo[which.min(
  criterios$AIC)], "\n")

# 8. DIAGNÓSTICO FINAL ----

cat("\n=== DIAGNÓSTICO FINAL DO MELHOR MODELO ===\n")
checkresiduals(melhor_modelo)
tsdiag(melhor_modelo)
autoplot(melhor_modelo)

cat("\n=== ANÁLISE CONCLUÍDA ===\n")

```

Referências Bibliográficas

MORETTIN, P. A.; TOLOI, C. M. C. **Análise de séries temporais**. 2. ed. São Paulo: Blucher, 2006.

Posit team. **RStudio: Integrated Development Environment for R**. Boston, MA, 2024. RStudio version 2024.12.0+467, "Kousa Dogwood". Disponível em: <<http://www.posit.co/>>.

R Core Team. **R: A Language and Environment for Statistical Computing**. Vienna, Austria, 2024. R version 4.4.2 (2024-10-31). Disponível em: <<https://www.R-project.org/>>.