



UNIVERSIDADE FEDERAL DO CEARÁ
CENTRO DE CIÊNCIAS
DEPARTAMENTO DE ESTATÍSTICA E MATEMÁTICA APLICADA
CURSO DE GRADUAÇÃO EM ESTATÍSTICA

DOUGLAS CHAVES MOURA

Segunda Prova Prática - Séries Temporais

FORTALEZA

2025

DOUGLAS CHAVES MOURA

Segunda Prova Prática - Séries Temporais

Trabalho apresentado à disciplina Análise de Séries Temporais, do curso de Graduação em Estatística do Centro de Ciências da Universidade Federal do Ceará, como parte dos requisitos para a avaliação da referida disciplina, no semestre 2025.1.

Professora: Dr^a Jeniffer Johana Duarte Sanchez

FORTALEZA

2025

Lista de Figuras

2.1	Gráfico da Série Temporal.	3
2.2	Histograma da variação percentual com densidade ajustada.	4
2.3	Boxplot da variação percentual dos gastos por trimestre.	5
2.4	Decomposição da Série Temporal.	6
3.1	Série após uma diferenciação.	10
3.2	Série após transformação logarítmica e uma diferenciação.	11
3.3	Função de Autocorrelação.	12
3.4	Função de Autocorrelação Parcial.	12
3.5	Diagnóstico dos resíduos (ACF e PACF) para o Modelo 1.	13
3.6	Diagnóstico dos resíduos (ACF e PACF) para o Modelo 2.	14
3.7	Valores-p para o Teste de Ljung-Box - Modelo 2.	15
3.8	Diagnóstico dos resíduos (ACF e PACF) para o Modelo 3.	16
3.9	Valores-p para o Teste de Ljung-Box - Modelo 3.	17
3.10	Q-Q Plot dos resíduos – Modelo 3.	17
5.1	Previsões para os próximos 12 meses com o Modelo 2.	20

Lista de Tabelas

2.1	Estatísticas descritivas da variação percentual nos gastos de consumo pessoal. .	2
2.2	Estatísticas descritivas mensais das despesas governamentais no plano de benefícios farmacêuticos, com base na série histórica.	2
4.1	Resumo comparativo dos indicadores para os modelos candidatos.	19

Sumário

Lista de Figuras

Lista de Tabelas

1	Introdução	1
2	Análise Exploratória e Descritiva	2
2.1	Descrição e Visualização dos Dados	2
2.2	Decomposição da Série	5
2.3	Testes Formais na Série Original	6
2.3.1	Teste para Estacionariedade	7
2.3.2	Teste para Tendência	8
2.3.3	Teste para Sazonalidade	9
3	Metodologia Box-Jenkins: Identificação, Estimação e Diagnóstico	10
3.1	Transformação Logarítmica	11
3.2	Identificação dos Parâmetros	11
3.3	Diagnóstico dos Modelos	13
3.3.1	Modelo SARIMA(0,1,1)(0,1,1) ₁₂	13
3.3.2	Modelo SARIMA(0,1,3)(0,1,1) ₁₂	13
3.3.3	Modelo SARIMA(1,1,4)(0,1,1) ₁₂	15
4	Escolha do Modelo Ideal	19
4.1	Análise Comparativa dos Resultados	19
5	Previsão	20
6	Analisando Dados Atípicos	21
7	Conclusão	22
	Referências Bibliográficas	23

1 Introdução

O seguinte trabalho busca analisar um conjunto de dados por meio da metodologia de Séries Temporais. O objetivo é identificar a estrutura estocástica da série, ajustar um modelo preditivo adequado e realizar previsões.

A base de todo o desenvolvimento metodológico foi coletada do livro "Análise de Séries Temporais" de [Morettin e Tolo \(2006\)](#), além dos conceitos vistos em sala de aula. A metodologia principal a ser seguida é a de Box-Jenkins para modelos ARIMA.

Toda a aplicação será desenvolvida no software R (Versão 4.4.2) ([R Core Team, 2024](#)), através da IDE (Integrated Development Environment) RStudio (Versão 2024.12.0.467) ([Posit team, 2024](#)).

2 Análise Exploratória e Descritiva

2.1 Descrição e Visualização dos Dados

A série temporal em estudo refere-se às despesas governamentais no plano de benefícios farmacêuticos, iniciando em julho de 1970 e encerrando-se em junho de 2008, totalizando 204 observações. Trata-se, portanto, de uma série temporal discreta (registrada a cada mês) e univariada. As principais estatísticas descritivas da variável estão apresentadas na Tabela 2.1.

Tabela 2.1: Estatísticas descritivas da variação percentual nos gastos de consumo pessoal.

Variável	Média	DP	EP	Mediana	Assimetria	Curtose	Min	Max	<i>n</i>
Despesas	10,69	5,96	0,42	9,32	0,83	-0,03	2,81	29,67	204


Considerando que a série é anual (período de 12 meses), as estatísticas descritivas também foram analisadas separadamente por mês, conforme apresentado na Tabela 2.2.

Tabela 2.2: Estatísticas descritivas mensais das despesas governamentais no plano de benefícios farmacêuticos, com base na série histórica.

Mês	Média	DP	EP	Mediana	Assimetria	Curtose	Min	Max	<i>n</i>
Janeiro	14,17	7,74	1,88	12,51	0,62	-0,96	5,09	29,67	17
Fevereiro	8,61	5,10	1,24	7,46	1,00	0,20	2,81	21,65	17
Março	9,49	5,09	1,23	8,59	0,55	-0,95	2,99	19,79	17
Abril	9,55	5,35	1,30	8,47	0,85	-0,01	3,20	23,11	17
Maio	10,56	5,98	1,45	9,39	0,61	-0,86	3,13	22,91	17
Junho	10,22	5,41	1,31	9,56	0,49	-1,10	3,27	20,68	17
Julho	9,99	5,37	1,30	8,72	0,53	-0,88	3,53	21,83	17
Agosto	10,26	5,89	1,43	9,07	0,72	-0,55	3,18	23,93	17
Setembro	10,23	5,66	1,37	9,18	0,63	-0,75	3,25	22,93	17
Outubro	11,02	6,11	1,48	9,25	0,53	-1,03	3,61	23,26	17
Novembro	11,49	6,68	1,62	9,93	0,68	-0,83	3,57	25,25	17
Dezembro	12,73	6,35	1,54	11,53	0,57	-0,92	4,31	25,81	17

A Figura 2.1 apresenta o gráfico da série temporal.


Figura 2.1: Gráfico da Série Temporal.



Visualmente, observa-se um comportamento de crescimento constante ao longo dos anos da série histórica. No entanto, é perceptível uma variação acentuada entre os meses de alguns anos — especialmente durante os anos de 2004 a 2008, onde ocorreram as maiores oscilações.

A distribuição empírica da série é apresentada por meio do histograma da Figura 2.2.


Figura 2.2: Histograma da variação percentual com densidade ajustada.



Nota-se que os dados não seguem uma distribuição perfeitamente simétrica, havendo observações dispersas nas caudas — especialmente na cauda inferior — o que sugere leve assimetria positiva.

Para investigar a variabilidade entre os trimestres, foi construído um boxplot da variável de interesse separado por cada mês (Figura 2.3).

Figura 2.3: Boxplot da variação percentual dos gastos por trimestre.




As medianas mensais são relativamente próximas - exceto pelo mês de Janeiro, mas a dispersão varia entre os períodos. Nos meses de Agosto e Novembro, foram identificadas observações consideradas *outliers*, reforçando a presença de valores atípicos ao longo da série.

2.2 Decomposição da Série

Para analisar melhor as suposições, vamos decompor a série em seus componentes.

Nesta etapa, vamos separar a série temporal em partes para vermos o seu comportamento de maneira mais clara, para isso decompos a série em seus componentes de tendência, sazonalidade e resíduo.

Figura 2.4: Decomposição da Série Temporal.



Através da visualização da figura 2.4 observamos no primeiro “sub-gráfico” os valores da série - assim como na figura 2.1.

Já no segundo “sub-gráfico” vemos o comportamento separado da tendência da série, onde observa-se uma característica de crescimento constante, principalmente na década de 2000, onde se tem um crescimento mais acentuado.

No terceiro “sub-gráfico” têm-se a sazonalidade da série que, de modo geral, apresenta um padrão claro, não tendo muito destaque.

Por fim, o último “sub-gráfico” mostra o componente de erro da série - no caso da decomposição aditiva $Y_t = T_t \times S_t \times \varepsilon_t$, sendo T_t : o componente de Tendência; S_t : o componente Sazonal; e ε_t : o que sobra após a remoção da tendência e da sazonalidade.

2.3 Testes Formais na Série Original

Para essa etapa, vamos formalizar as primeiras ideias que havíamos comentado através da análise visual feita anteriormente. Iremos confirmar ou não a presença de estacionariedade, tendência e sazonalidade com alguns testes estatísticos próprios para cada um.

2.3.1 Teste para Estacionariedade

Pelo teste de Dickey-Fuller Aumentado (ADF) a série é estacionária (valor- p igual a 0,01), mas pelo teste de KPSS nós rejeitamos a hipótese de que a série é estacionária em torno de uma média (valor- $p < 0,01$).

TESTE DE ESTACIONARIEDADE - ADF

```
> # Teste de Dickey-Fuller Aumentado (ADF)
> # H0: série possui raiz unitária (não estacionária)
> # H1: série é estacionária
> adf.test(serie_despesas)
```

Augmented Dickey-Fuller Test

```
data:  serie_despesas
Dickey-Fuller = -4.1233, Lag order = 5, p-value = 0.01
alternative hypothesis: stationary
```

TESTE DE ESTACIONARIEDADE - KPSS

```
> # Teste de Kwiatkowski-Phillips-Schmidt-Shin (KPSS)
> # H0: série é estacionária em torno de uma média ou tendê
    ncia
> # H1: série possui raiz unitária (não estacionária)
> kpss.test(serie_despesas)
```

KPSS Test for Level Stationarity

```
data:  serie_despesas
KPSS Level = 3.827, Truncation lag parameter = 4, p-value =
    0.01
```

Isso ocorre pois o teste ADF tem como hipótese nula a verificação da raiz unitária em uma série.

Como visto pela análise gráfica (2.1) e a decomposição da série (2.4), concluímos então que as despesas governamentais - nesse período de estudo - não são estacionárias.

2.3.2 Teste para Tendência

Pelo teste de tendência monotônica da série - Mann-Kendall, temos um indicativo de haver sim uma tendência de caráter positivo - através do resultado $\tau = 0,847$ do teste, e um valor- p bem inferior ao nível de significância de 5%. Já o teste de Regressão Linear Simples para Tendência também evidencia um valor- p menor que 5% para o termo “tempo”, rejeita-se a hipótese de não haver tendência.

TESTE DE TENDÊNCIA - Mann-Kendall

```
> # Teste de Mann-Kendall
> # H0: não há tendência monotônica na série
> # H1: existe tendência monotônica
> MannKendall(serie_despesas)
tau = 0.847, 2-sided pvalue =< 2.22e-16
```

TESTE DE TENDÊNCIA - Regressão Linear Simples

```
> # Teste de Regressão Linear para Tendência
> # H0: coeficiente de tendência = 0 (sem tendência)
> # H1: coeficiente de tendência != 0 (com tendência)
> tempo <- 1:length(serie_despesas)
> modelo_tendencia <- lm(serie_despesas ~ tempo)
> summary(modelo_tendencia)
```

Call:

```
lm(formula = serie_despesas ~ tempo)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-5.0153	-1.5800	-0.3347	1.1413	9.9670

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.130721	0.319622	3.538	0.000501 ***
tempo	0.093304	0.002704	34.509	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
Residual standard error: 2.274 on 202 degrees of freedom  
Multiple R-squared: 0.855, Adjusted R-squared: 0.8543  
F-statistic: 1191 on 1 and 202 DF, p-value: < 2.2e-16
```

2.3.3 Teste para Sazonalidade

Já para o teste de sazonalidade QS (*Quadratic Spectral*) temos um valor- p igual a 0 (zero), evidenciando uma forte característica de haver sazonalidade. Como visto na figura 2.4, na parte que mostra a decomposição da série em sazonalidade, temos essa característica nesta série temporal.

TESTE DE SAZONALIDADE - QS

```
> # Teste QS (Quadratic Spectral) para Sazonalidade  
> # H0: não há sazonalidade estável  
> # H1: existe sazonalidade estável  
> qs(serie_despesas, freq = frequency(serie_despesas))  
Test used: QS  
  
Test statistic: 212.81  
P-value: 0
```

3 Metodologia Box-Jenkins: Identificação, Estimação e Diagnóstico


Neste capítulo, detalha-se a construção do modelo SARIMA, que é adequado para séries com sazonalidade estocástica. A forma geral de um modelo SARIMA(p, d, q)(P, D, Q) $_s$ é:

$$\phi_p(B)\Phi_P(B^s)(1-B)^d(1-B^s)^D Z_t = \theta_q(B)\Theta_Q(B^s)a_t \quad (3.1)$$

onde B é o operador de defasagem e $a_t \sim RB(0, \sigma_a^2)$ é um ruído branco.

Como primeiro passo, vamos analisar a primeira diferença da série (Despesas Governamentais) para deixá-la estacionária.

Figura 3.1: Série após uma diferenciação.



A análise exploratória revelou que a variabilidade da série não é constante, tendendo a aumentar conforme o nível da produção cresce. Uma das premissas dos modelos ARIMA é a estabilidade da variância (homocedasticidade), e a transformação logarítmica é uma técnica clássica para estabilizar essa variância.


Vê-se que existe uma alta variabilidade nos anos finais da série - entre 2000 a 2008.

Devido a essa característica do gráfico da primeira diferença da série, é necessária a aplicação da transformação logarítmica, pois a variância não é homoscedástica.

3.1 Transformação Logarítmica

Apesar de a primeira diferença ter removido a tendência, a variabilidade ainda não parece constante. Para resolver ambas as questões — estacionariedade na média e na variância — a abordagem mais robusta é combinar as duas técnicas: aplicar a primeira diferença na série já transformada por logaritmo.

Figura 3.2: Série após transformação logarítmica e uma diferenciação.



O resultado (Figura 3.2) é uma série que visualmente aparenta ser muito mais estável, flutuando em torno de zero e com uma variabilidade mais homogênea. A variância desta nova série é de apenas 0,3265, um valor extremamente baixo que indica uma grande estabilização. A interpretação desta série transformada é a da **taxa de crescimento mensal (aproximada) das despesas governamentais**.

3.2 Identificação dos Parâmetros

Análise ACF e PACF para identificar p e q . Com a série estacionária, analisamos seus gráficos de Autocorrelação (ACF) e Autocorrelação Parcial (PACF) para identificar as ordens p do modelo Auto-Regressivo (AR) e q do modelo de Médias Móveis (MA).

Figura 3.3: Função de Autocorrelação.





Figura 3.4: Função de Autocorrelação Parcial.



Através do gráfico da função de autocorrelação (3.3) vemos o primeiro *lag* sendo significativo, também os *lags* 12 e 24 demonstram uma autocorrelação significativa, o que sugere a adição de um MA de ordem 1 para a parte sazonal e não sazonal.

Já no gráfico da função de autocorrelação parcial (3.4), têm-se um comportamento de decaimento senoidal para os *lags* iniciais, sendo os *lags* 1, 2, 3, 4 significativos. O *lag* 12, e seus vizinhos também demonstram uma autocorrelação significativa.


3.3 Diagnóstico dos Modelos

Com base nessa primeira análise, foi desenvolvido o modelo SARIMA(0,1,1)(0,1,1)₁₂

3.3.1 Modelo SARIMA(0,1,1)(0,1,1)₁₂

Este modelo inicial foi ajustado com base nas principais características observadas no ACF/PACF. A análise de seus resíduos (Figura 3.5) revelou um problema.

Figura 3.5: Diagnóstico dos resíduos (ACF e PACF) para o Modelo 1.




Embora muitas autocorrelações tenham sido removidas, observa-se uma **correlação residual significativa no lag 3**, no ACF e PACF, além de autocorrelação significativa em alguns *lags* acima do 12. Isso indica que o modelo não capturou toda a estrutura de dependência temporal dos dados.

3.3.2 Modelo SARIMA(0,1,3)(0,1,1)₁₂

Como proposta para o segundo modelo, ajustamos um modelo SARIMA(0,1,3)(0,1,1)₁₂ pois vimos que existia uma autocorrelação forte no ACF.

A análise dos resíduos do segundo modelo é apresentada na figura 3.6


Figura 3.6: Diagnóstico dos resíduos (ACF e PACF) para o Modelo 2.



Vemos que nos *lags* iniciais houve uma melhora, entretanto o *lag* 4 permanece fora dos limites aceitáveis, tanto no ACF quanto no PACF - embora seja em uma magnitude ínfima. Os *lags* 19 e 24 ainda apresentam significância.

Análise de resíduos Para verificar a adequação do modelo $SARIMA(0,1,3)(0,1,1)_{12}$, analisamos os resíduos estimados. O objetivo é avaliar se estes se comportam como ruído branco, ou seja, independentes, com média zero, variância constante e distribuição aproximadamente normal.

Figura 3.7: Valores-p para o Teste de Ljung-Box - Modelo 2.




Vemos que esse modelo não é bem ajustado para essa série em estudo. Como continuidade das análises, vamos verificar se existe.

3.3.3 Modelo SARIMA(1,1,4)(0,1,1)₁₂

Como último modelo a ser aplicado, vamos desenvolver um SARIMA(1,1,4)(0,1,1)₁₂. Esse modelo é pensado no primeiro *lag* significativo do 3.4 e, conseqüentemente, à adição de mais um MA não sazonal, como visto na figura 3.6.


Figura 3.8: Diagnóstico dos resíduos (ACF e PACF) para o Modelo 3.



É observada uma grande melhora no modelo, onde todos os *lags* iniciais têm sua autocorrelação capturada. Embora haja alguns *lags* significativos, eles são de um período distante, e não ultrapassam os limites com grande magnitude.


Análise de resíduos O gráfico com os valores-*p* para o Teste de Ljung-Box são apresentados na figura 3.9.

Figura 3.9: Valores-p para o Teste de Ljung-Box - Modelo 3.



O teste de Ljung-Box (Figura 3.9) corrobora essa conclusão, com todos os valores- p acima do nível de significância de 5%, indicando a ausência de autocorrelação serial nos resíduos.

Figura 3.10: Q-Q Plot dos resíduos – Modelo 3.



O gráfico Q-Q plot da Figura 3.10 revela leve assimetria à esquerda e caudas mais pesadas,

o que compromete a suposição de normalidade. Essa observação é corroborada pelos testes:

- **Shapiro-Wilk:** valor- $p < 0,02241 \Rightarrow$ rejeita a hipótese nula de normalidade;
- **Jarque-Bera:** valor- $p = 0,003562 \Rightarrow$ rejeita fortemente a hipótese nula de normalidade.

4 Escolha do Modelo Ideal

Este capítulo realiza a análise comparativa final entre os modelos SARIMA(0,1,1)(0,1,1)₁₂; SARIMA(0,1,3)(0,1,1)₁₂ e SARIMA(1,1,4)(0,1,1)₁₂ propostos para a série de despesas.

4.1 Análise Comparativa dos Resultados

Para permitir uma avaliação direta, os principais indicadores de desempenho de cada modelo foram consolidados na Tabela 4.1. A Tabela 4.1 compara os dois modelos com base em critérios de ajuste e parcimônia.

Tabela 4.1: Resumo comparativo dos indicadores para os modelos candidatos.


Critério	Modelo 1	Modelo 2	Modelo 3
<i>Ajuste e Parcimônia</i>			
Log-Verossimilhança (ℓ)	255,24	259,12	263,05
AIC	-504,49	-508,25	-512,10
AICc	-504,36	-507,93	-511,49
BIC	-494,73	-491,99	-489,34
Variância dos Resíduos ($\hat{\sigma}^2$)	0,003847	0,003743	0,003623
<i>Acurácia no Conjunto de Treinamento</i>			
RMSE	0,0597	0,0586	0,0573
MAE	0,0449	0,0432	0,0427
MAPE (%)	2,01	1,95	1,92
MASE	0,3642	0,3503	0,3460

SARIMA(1,1,4)(0,1,1)₁₂ Obteve as melhores métricas dentre todos os modelos, além de ter tido bom desempenho nas análises de resíduos. Embora os resíduos não se sigam uma distribuição normal, isso não impede a utilização e escolha desse modelo.

5 Previsão

Utilizando o modelo SARIMA(1,1,4)(0,1,1)₁₂ - modelo final escolhido -, foram geradas previsões para os próximos 12 meses. A Figura 5.1 mostra as previsões junto com os dados históricos.

Figura 5.1: Previsões para os próximos 12 meses com o Modelo 2.



As previsões capturam bem o padrão sazonal da série, projetando um ciclo anual consistente com o comportamento histórico. Os intervalos de confiança (áreas sombreadas) fornecem uma faixa plausível para os valores futuros.

6 Analisando Dados Atípicos

Através da função `detectIO` temos que o índice 42 - referente a Dezembro de 1994 - é considerada uma observação *outlier* de cunho inovativo. Já a função `detectAO` não mostrou nenhum índice como sendo um *outlier* aditivo.

7 Conclusão

Temos como modelo final o SARIMA(1,1,4)(0,1,1)₁₂, dado por:

$$(1 - \phi_1 B)(1 - B)(1 - B^{12}) \log(Z_t) = (1 + \theta_1 B + \theta_2 B^2 + \theta_3 B^3 + \theta_4 B^4)(1 + \Theta_1 B^{12})a_t, \quad a_t \sim \text{RB}(0, \sigma_a^2)$$

A equação com as respectivas estimativas dos parâmetros é :

$$(1 + 0,5357B)(1 - B)(1 - B^{12}) \log(Z_t) = (1 + (-0,3914)B + (-0,2626)B^2 + (0,1591)B^3 + (-0,2572)B^4)(1 + (-0,7457)B^{12})a_t$$

com $a_t \sim \text{RB}(0, 0,003623)$, e todos os parâmetros significativos para a composição do modelo.

Vimos que esse modelo é aprovado nos testes e nas análises feitas, mostrando-se uma boa escolha na modelagem e previsão de futuros valores das despesas governamentais no plano de benefícios farmacêuticos.

Referências Bibliográficas

MORETTIN, P. A.; TOLOI, C. M. C. **Análise de séries temporais**. 2. ed. São Paulo: Blucher, 2006.

Posit team. **RStudio: Integrated Development Environment for R**. Boston, MA, 2024. RStudio version 2024.12.0+467, "Kousa Dogwood". Disponível em: <<http://www.posit.co/>>.

R Core Team. **R: A Language and Environment for Statistical Computing**. Vienna, Austria, 2024. R version 4.4.2 (2024-10-31). Disponível em: <<https://www.R-project.org/>>.